


## Parte III: IA e Incerteza.

Prof. Fabiano Araujo Soares, Dr. / FGA 0221 - Inteligência Artificial

Universidade de Brasília


2025

# Quantificando Incerteza



Como um agente pode tomar decisões corretas mesmo quando não conhece todos os fatos?

# Quantificando Incerteza



Como um agente pode tomar decisões corretas mesmo quando não conhece todos os fatos?

Inteligência precisa lidar com decisões sob informações imperfeitas: ignorar a incerteza é ignorar o mundo real.

# Motivação: Por Que Lidar com Incerteza?

- Agentes no mundo real precisam lidar com a incerteza, seja devido à observabilidade parcial, não determinismo, limitações ou adversidades.
- Até o momento, vimos agentes lógicos lidarem com a incerteza acompanhando todos os estados de mundo possíveis em que possam estar.
- Essa abordagem funciona em problemas simples, mas possui desvantagens:
  - O agente deve considerar todas as explicações possíveis (mesmo as mais improváveis);
  - Plano de contingência que lide com todas as eventualidades pode ser computacionalmente inviável;
  - Às vezes, não há garantia de alcance da meta, mas o agente deve agir mesmo assim.
- Logo o agente precisa de alguma estratégia para lidar com planos que não são garantidos.

## Exemplo de Agente lidando com Incerteza.

Imagine que um agente de Smart Taxi precisa atender um cliente que terá um voo as 21h e por isso precisa chegar ao aeroporto às 20h, no entanto o agente sabe dos seguintes fatos:

- O tempo médio para chegar ao aeroporto é de 30 min em transito médio, 45 min em transito pesado e 20 min em transito leve;
- Entre as 19h e às 21h o transito é médio, entre as 17h e às 19h o transito é pesado;
- Quando chove o transito é sempre pesado;
- Existe 50% de chances de chuva no dia do voo;
- Existe uma chance de 5% de haver acidente na rota, e caso isso ocorra, o tempo para chegada ao aeroporto aumenta em 10 min por acidente, independente do tráfego.
- Existem uma série de outras condições que podem ocorrer mas não são previsíveis.

## Exemplo de Agente lidando com Incerteza.

Imagine que um agente de Smart Taxi precisa atender um cliente que terá um voo as 21h e por isso precisa chegar ao aeroporto às 20h, no entanto o agente sabe dos seguintes fatos:

- O tempo médio para chegar ao aeroporto é de 30 min em transito médio, 45 min em transito pesado e 20 min em transito leve;
- Entre as 19h e às 21h o transito é médio, entre as 17h e às 19h o transito é pesado;
- Quando chove o transito é sempre pesado;
- Existe 50% de chances de chuva no dia do voo;
- Existe uma chance de 5% de haver acidente na rota, e caso isso ocorra, o tempo para chegada ao aeroporto aumenta em 10 min por acidente, independente do tráfego.
- Existem uma série de outras condições que podem ocorrer mas não são previsíveis.

Qual é o melhor plano para chegar com segurança no aeroporto?

# Incerteza e lógica proposicional

- Vamos considerar um exemplo de raciocínio incerto: diagnosticar a dor de dente de um paciente odontológico;
- O diagnóstico - seja para medicina, conserto de automóveis ou qualquer outra coisa - quase sempre envolve incerteza.
- Vamos tentar escrever regras para diagnóstico odontológico usando lógica proposicional:
  - Dor de dente  $\implies$  Cárie (Errado! Nem toda dor de dente está relacionado à cáries);
  - Dor de dente  $\implies$  Cárie  $\vee$  Gengivite  $\vee$  Abscesso  $\vee$  ... (lista grande);
  - Cárie  $\implies$  Dor de dente (Errado! Nem toda cárie está relacionada a dor);
- A única maneira de corrigir a regra é torná-lo logicamente exaustiva: aumentar o lado esquerdo com todas as qualificações necessárias para que uma cárie cause dor de dente.

# Como lidar com incerteza?

- Tentar usar a lógica para lidar com um domínio como o diagnóstico médico não é prático por três razões:
  - **Complexidade:** É trabalhoso listar o conjunto completo de antecedentes ou consequentes necessário para garantir uma regra sem exceções e é muito difícil usar essas regras.
  - **Ignorância teórica:** A ciência médica não tem uma teoria completa para o seu domínio.
  - **Ignorância prática:** Mesmo que conheçamos todas as regras, podemos estar incertos sobre um determinado paciente porque nem todos os testes necessários foram ou podem ser executados.
- A conexão entre dores de dente e cáries não é uma consequência lógica estrita em ambas as direções.
- Isso é típico do domínio médico, bem como em vários outros domínios de julgamento: direito, negócios, design, reparo de automóveis, jardinagem, namoro e assim por diante.



# O que fazer?

- Quando o conhecimento do agente não é certo  $\implies$  **Probabilidade**.
- **compromissos ontológicos**: Iguais na lógica e na teoria das probabilidades — o mundo é composto de fatos que são válidos ou não em qualquer caso particular;
- **compromissos epistemológicos**: são diferentes — um agente lógico acredita que cada sentença é verdadeira ou falsa, um agente probabilístico possui um grau numérico de crença entre 0 (para sentenças que certamente são falsas) e 1 (certamente verdadeira).

## Teoria da Probabilidade

- **A teoria da probabilidade**: Lida com a incerteza que vem de nossa falta de tempo, ignorância ou limitação.
- Podemos não ter certeza sobre o que aflige um paciente em particular, mas acreditamos que há, digamos, 80% de chance — isto é, uma probabilidade de 0,8 - que o paciente que reclama de dor de dente tenha uma cárie.

- **Retornando ao exemplo do smart taxi:** existem várias soluções possíveis para o cliente, no entanto, ele certamente possui preferências;
- Usaremos a **teoria da utilidade** para representar preferências e raciocinar quantitativamente a respeito dos possíveis resultados;
- A teoria da utilidade diz que todo estado (ou sequência de estados) tem um **grau de utilidade**, para um agente e que o agente preferirá estados com maior utilidade;
- A utilidade de um estado é relativa a um agente;
- Uma **função de utilidade** pode levar em conta qualquer conjunto de preferências — peculiares ou típicas, nobres ou perversas.

- As preferências, expressas pelas utilidades, são combinadas com as probabilidades para formar a **teoria de decisão**:

## Teoria da Decisão

$$\text{Decisão} = \text{Probabilidade} + \text{Utilidade}$$

- **Teoria da decisão**: Um agente é racional se e somente se escolhe a ação que produz a **maior utilidade esperada** calculada pela média de todos os resultados possíveis da ação;
- Isso é chamado de princípio da utilidade máxima esperada (MEU, do inglês *maximum expected utility*);

**function** DT-AGENT(*percept*) **returns** an *action*

**persistent:** *belief\_state*, probabilistic beliefs about the current state of the world  
*action*, the agent's action

update *belief\_state* based on *action* and *percept*

calculate outcome probabilities for actions,

given action descriptions and current *belief\_state*

select *action* with highest expected utility

given probabilities of outcomes and utility information

**return** *action*

# Fundamentos de Probabilidade

- Em teoria de probabilidade, o conjunto de todos os estados de mundos possíveis é chamado de **espaço amostral**;
- Os estados de mundos possíveis são **mutuamente exclusivas** e **exaustivas**;
- A letra grega  $\Omega$  é usada para representar o espaço amostral e a letra  $\omega$  é usada para representar um elemento do espaço amostral;
- O axioma básico de probabilidade diz que todo estado de mundo possível possui uma probabilidade entre 0 e 1 e a probabilidade do conjunto de estados de mundo possíveis é 1:

$$0 \leq P(\omega) \leq 1 \text{ para todo } \omega \text{ e } \sum_{\omega \in \Omega} P(\omega) = 1.$$

# Noção básica de probabilidade

- Por exemplo, imagine um lance de dois dados de 6 lados justos, os resultados possíveis seriam:  $(1,1)$ ,  $(1,2)$ ,  $(1,3)$ ,...  $(6,6)$ ;
- Considerando os dados justos, a probabilidade de cada resultado possível é  $1/36$ ;
- Afirmarções e consultas probabilísticas geralmente são sobre conjuntos de realizações;
- **Por exemplo:** qual a probabilidade de dois dados somarem 11, ou a probabilidade de que os dados rolem o mesmo número, etc;
- Na teoria da probabilidade, esses conjuntos são chamados de eventos.

# Comparação com a Lógica Proposicional

- Em **lógica** esses conjuntos são chamados de **proposições** e é basicamente sinônimo do termo **eventos** em probabilidade, mas as proposições são escritas com linguagem formal.
- A **probabilidade** associada à uma **proposição** é definida como sendo a soma das probabilidades dos mundos em que ela é válida:

$$P(\phi) = \sum_{\omega \in \phi} P(\omega)$$

onde  $\phi$  é uma proposição.

# Noção básica de probabilidade

- Vamos considerar dois casos para o lançamento de dois dados:

- Obter uma soma de 11 em dados justos:

$$P(Total = 11) = P(5, 6) + P(6, 5) = \frac{1}{36} + \frac{1}{36} = \frac{1}{18}.$$

- Os dados favorecem números iguais 25% das vezes (Dados Tendenciosos):

$$P(Duplos) = \frac{1}{4}$$

- No segundo caso, sabemos a probabilidade de duplos sem saber se os dados preferem duplos 6 a duplos 2, etc. Assim como em asserções lógicas, essa asserção restringe o modelo de probabilidade subjacente sem determiná-lo completamente.



# Noção básica de probabilidade

- Probabilidades como  $P(\text{Total} = 11)$  ou  $P(\text{Duplos})$  são chamadas de probabilidades **incondicionais** ou probabilidades *a priori*.
- Na maioria das vezes, temos informações já reveladas que chamamos de **evidência**.
- Por exemplo, digamos que lancemos primeiro um dado e tiramos 5, qual a probabilidade de termos um duplo?
- Nesse caso, não estamos interessados na probabilidade incondicional de rolar duplos, mas a probabilidade **condicional** ou *a posteriori*.

# Noção básica de probabilidade

- Essa probabilidade é escrita como:  $P(\text{Duplos} \mid \text{Dado}_1 = 5)$
- As probabilidades *a posteriori* são definidas em termos de probabilidades *a priori* da seguinte forma: para quaisquer proposições  $a$  e  $b$ , temos:

$$P(a \mid b) = \frac{P(a \wedge b)}{P(b)}, \text{ para qualquer } P(b) > 0$$

- Por exemplo:

$$P(\text{Duplos} \mid \text{Dado}_1 = 5) = \frac{P(\text{Duplos} \wedge \text{Dado}_1 = 5)}{P(\text{Dado}_1 = 5)}.$$

- A definição de **probabilidade condicional** (ou *a posteriori*), pode ser escrita em um forma chamada de **regra do produto**:

## Regra do produto

$$P(a \wedge b) = P(a \mid b)P(b)$$

# Noção básica de probabilidade

- Variáveis em teoria de probabilidade são chamadas de **variáveis aleatórias** e seus nomes iniciam com uma letra maiúscula (exemplo:  $Dado_1$ );
- Toda **variável aleatória** mapeia do **espaço amostral** para uma faixa de valores — o conjunto de valores que essa variável pode assumir (exemplo para o lance de dois dados:  $\{2, \dots, 12\}$ , Para o lance do primeiro dado  $Dado_1 = \{1, \dots, 6\}$ ;
- Nomes de valores são escritos com letras minúsculas, por exemplo:

$$\sum_x P(X = x)$$

- Variáveis Booleanas tem a faixa verdadeiro, falso ou 0, 1;
- Proposições da forma  $A = \text{verdadeiro}$  é abreviada na forma  $a$  enquanto  $A = \text{falso}$  é abreviado como  $\neg a$ .

# Noção básica de probabilidade

- Os intervalos podem ser conjuntos de símbolos arbitrários como  $Idade = \{juvenil, adolescente, adulto\}$  ou  $Tempo = \{sol, chuva, nublado, neve\}$ ;
- Variáveis podem ter uma faixa infinita discreta ou contínua;
- Inequalidades são permitidas como  $NumeroDeAtomosNoUniverso \geq 10^{70}$ ;
- Finalmente, podemos combinar esses tipos de proposições elementares usando os conectivos da lógica proposicional, por exemplo: “A probabilidade do paciente possuir uma cárie dado que ele é um adolescente e não possui dor de dente é 0,1”:

$$P(Cárie \mid \neg DorDeDente \wedge Jovem) = 0,1.$$

# Noção básica de probabilidade

- Em probabilidade, também é comum utilizar vírgula para representar conjunção, então podemos reescrever a proposição anterior como

$$P(Cárie \mid \neg DorDeDente, Jovem) = 0,1.$$

- Algumas vezes, precisamos falar de todos os valores de uma variável aleatória, nesse caso, podemos escrever:

$$P(Tempo = Sol) = 0,6$$

$$P(Tempo = Chuva) = 0,1$$

$$P(Tempo = Nublado) = 0,29$$

$$P(Tempo = Neve) = 0,01$$

- ou:

$$P(Tempo) = \langle 0.6, 0.1, 0.29, 0.01 \rangle$$

# Noção básica de probabilidade

- Aqui o **P** em negrito indica que o resultado é um vetor de números onde assumimos uma ordenação predefinida  $\langle \text{sol}, \text{chuva}, \text{nublado}, \text{neve} \rangle$  na faixa de Tempo.
- Dizemos que o **P** define uma **distribuição de probabilidade** para a variável aleatória Tempo.
- A notação **P** também é usada para distribuições condicionais:  $\mathbf{P}(X \mid Y)$  fornece os valores de  $\mathbf{P}(X = x_i \mid Y = y_j)$  para cada par  $i, j$  possível.

- Para variáveis aleatórias contínuas utilizamos a **função densidade de probabilidade** (PDF do inglês *probability density function*) com a notação:

$$P(TemperaturaNoturna = x) = Uniform(x; 18^{\circ}C; 26^{\circ}C)$$

- Que significa que a temperatura noturna varia uniformemente entre 18 e 26 graus celsius.
- Escrevemos a densidade de probabilidade para uma variável aleatória discreta  $X$  no valor  $x$  como  $P(X = x)$  ou apenas  $P(x)$ .



# Noção básica de probabilidade

- Além de distribuições em variáveis únicas, precisamos de notação para distribuições em múltiplas variáveis. As vírgulas são usadas para isso.
- Por exemplo, se desejarmos a distribuição conjunta de probabilidade entre tempo e cárie teríamos:

$$P(\textit{Tempo}, \textit{Cárie}) = P(\textit{Tempo} \mid \textit{Cárie})P(\textit{Cárie})$$

- ao invés de

$$P(T = \textit{sol} \wedge C = \textit{Verdadeiro})P(T = \textit{sol} \mid C = \textit{Verdadeiro})P(C = \textit{Verdadeiro})$$

$$P(T = \textit{chuva} \wedge C = \textit{Verdadeiro})P(T = \textit{chuva} \mid C = \textit{Verdadeiro})P(C = \textit{Verdadeiro})$$

$$P(T = \textit{nublado} \wedge C = \textit{Verdadeiro})P(T = \textit{nublado} \mid C = \textit{Verdadeiro})P(C = \textit{Verdadeiro})$$

⋮

# Noção básica de probabilidade

- Essa notação também pode ser usada para valores de variáveis, como  $P(sol, \text{cárie})$ ;
- Para completar a semântica, precisamos dizer o que são os mundos e como determinar se uma proposição é válida em um mundo:
  - Um mundo possível é definido como uma atribuição de valores a todas as variáveis aleatórias em consideração.
- Um modelo de probabilidade é completamente determinado pela distribuição conjunta de todas as variáveis aleatórias - as chamadas **distribuição de probabilidade conjunta completa**.

# Noção básica de probabilidade

- Relação entre uma proposição e sua negação:

$$\begin{aligned}P(\neg a) &= \sum_{\omega \in \neg a} P(\omega) \\&= \sum_{\omega \in \neg a} P(\omega) + \sum_{\omega \in a} P(\omega) - \sum_{\omega \in a} P(\omega) \\&= \sum_{\omega \in \Omega} P(\omega) - \sum_{\omega \in a} P(\omega) \\&= 1 - P(a)\end{aligned}$$

- Probabilidade para uma disjunção:

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$

# Noção básica de probabilidade

- Vamos usar um exemplo para discutir distribuição conjunta:
  - **Cavity** = Cárie = {verdadeiro, falso};
  - **Toothache** = dor de dente {verdadeiro, falso};
  - **Catch** = Sonda prende no dente = {verdadeiro, falso}.
- A distribuição de probabilidade conjunta para essas variáveis aleatórias é:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

# Noção básica de probabilidade

- A soma das probabilidades conjuntas é 1;
- Por exemplo, probabilidade para *cavity*  $\vee$  *toothache* é:

$$P(\text{cavity} \vee \text{toothache}) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28.$$

- Somar os valores da primeira linha da tabela nos dá a probabilidade incondicional de cárie:

$$P(\text{cavity}) = 0.108 + 0.012 + 0.072 + 0.008 = 0.2.$$

# Noção básica de probabilidade

- Esse processo é chamado de marginalização, ou somatório - porque somamos a probabilidade para cada valor possível das outras variáveis, retirando-as da equação.
- Para qualquer variável  $\mathbf{Y}$  e  $\mathbf{Z}$ , temos:

$$P(Y) = \sum_z P(Y, Z = z)$$

- Para o exemplo odontológico, teríamos:

$$\begin{aligned} P(Cavity) &= P(Cavity, toothache, catch) + P(Cavity, toothache, \neg catch) + \\ &\quad P(Cavity, \neg toothache, catch) + P(Cavity, \neg toothache, \neg catch) \\ P(Cavity) &= \langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle + \langle 0. - 72, 0.144 \rangle + \langle 0.008, 0.576 \rangle \\ P(Cavity) &= \langle 0.2, 0.8 \rangle \end{aligned}$$

# Noção básica de probabilidade

- Podemos substituir  $P(Y, z)$  na equação de marginalização por  $P(Y | z)P(z)$  para obter a **regra de condicionamento**:

## Regra de condicionamento

$$P(Y) = \sum_z P(Y | z)P(z)$$

- Na maioria dos casos, estamos interessados em calcular probabilidades condicionais de algumas variáveis, dadas evidências sobre outras.
- Por exemplo, podemos calcular a probabilidade de uma cárie, dada evidência de uma dor de dente, como:

$$P(\text{cavity} | \text{toothache}) = \frac{P(\text{cavity} \wedge \text{toothache})}{P(\text{toothache})} = \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = 0.6$$


# Noção básica de probabilidade

- Podemos verificar essa probabilidade calculando a probabilidade de não termos uma cárie e termos dor de dente:

$$\begin{aligned}P(\neg cavity \mid toothache) &= \frac{P(\neg cavity \wedge toothache)}{P(toothache)} \\&= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4\end{aligned}$$

- Usaremos  $\alpha$  como representação de uma constante para normalização de probabilidade:

$$\begin{aligned}P(cavity \mid toothache) &= \alpha P(cavity, toothache) \\&= \alpha [P(cavity, toothache, catch) + P(cavity, toothache, \neg catch)] \\&= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] = \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle\end{aligned}$$

  $\alpha = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$



- Diagnóstico em medicina
- Robótica com sensoriamento (precisão limitada pela tecnologia)
- Sistemas de recomendação
- Análise financeira e previsão de risco

- Modelagem adequada do problema e dependências
- Cálculo eficiente em redes grandes
- Obtenção de dados confiáveis

- Agentes inteligentes precisam tratar incertezas para agir no mundo real.
- Probabilidade e inferência são ferramentas cruciais.
- Abordagens modernas incluem redes Bayesianas, Markov, etc.

- Que estratégias a IA pode usar para aprender probabilidades a partir de dados?
- Quais limitações atuais precisamos superar para diagnosticar doenças raras de modo automatizado?
- Quando a heurística pode ser preferível ao modelo probabilístico completo?

- Russell, S. J., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. 4<sup>a</sup> ed.
- Slides oficiais: [aima.cs.berkeley.edu](http://aima.cs.berkeley.edu)
- Outros: materiais complementares em IA.

# Obrigado!

E-mail: [fabianosoares@unb.br](mailto:fabianosoares@unb.br)

LinkedIn: <https://www.linkedin.com/in/fabiano-soares-06b6a821a/>

Site do curso: <https://www.fabianosoares.eng.br/fga0221-inteligência-artificial>