

Parte III: IA e Incerteza.

Prof. Fabiano Araujo Soares, Dr. / FGA 0221 - Inteligência Artificial

Universidade de Brasília

2025



Como podemos ensinar uma máquina a mudar de ideia quando novas evidências surgem — e por que isso é essencial para a inteligência artificial do futuro?



Como podemos ensinar uma máquina a mudar de ideia quando novas evidências surgem — e por que isso é essencial para a inteligência artificial do futuro?

Nos métodos bayesianos, a incerteza não é um obstáculo — é a matéria-prima da inteligência.

Relembrando o modelo das variáveis odontológicas

- Vamos retornar ao modelo probabilístico para dor de dente (Toothache), cárie (Cavity) e sonda presa no dente (Catch).
- Agora, adicionando a variável 'Tempo atmosférico':

$$P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}, \textit{Weather})$$

- Qual a relação entre essas quatro variáveis?
- Podemos usar a regra do produto:

$$\begin{aligned} P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}, \textit{Weather}) &= \\ &= P(\textit{Cloud} \mid \textit{Toothache}, \textit{Catch}, \textit{Cavity})P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}) \end{aligned}$$

Independência entre variáveis

- A variável "tempo atmosférico" é independente das demais.
- Isso nos leva a simplificações importantes na fórmula da distribuição conjunta.
- Definição de independência: $P(a \wedge b) = P(a)P(b)$.
- Para variáveis, independência: $P(X, Y) = P(X)P(Y)$.
- Proposições de independência ajudam a reduzir a quantidade de informação a ser especificada.
- Podem facilitar a representação e a inferência em domínios complexos.

Independência entre variáveis

- Nesse caso teremos:

$$P(\textit{Cloud} \mid \textit{Toothache}, \textit{Catch}, \textit{Cavity}) = P(\textit{Cloud})$$


- Essa equação nos leva a:

$$P(\textit{Toothache}, \textit{Catch}, \textit{Cavity}, \textit{Weather}) = P(\textit{Toothache}, \textit{Catch}, \textit{Cavity})P(\textit{Weather})$$

Independência entre variáveis

- Determinar a independência de variáveis (ou proposições) pode reduzir dramaticamente a quantidade de informação para especificar a distribuição conjunta completa;
- Se o conjunto completo de variáveis pode ser dividido em subconjuntos independentes, então a distribuição conjunta completa pode ser fatorada em conjuntos separados;
- Quando estão disponíveis, proposições independentes podem ajudar a reduzir o tamanho da representação do domínio e a complexidade do problema de inferência.

Independência entre variáveis



Regra do Produto revisitada

- A regra do produto pode ser escrita de duas maneiras:

$$P(a \wedge b) = P(a)P(b|a)$$

$$P(a \wedge b) = P(b)P(a|b)$$

- Igualando e dividindo pelo lado direito leva à famosa Regra de Bayes.

$$P(b | a) = \frac{P(a | b)P(b)}{P(a)}$$

- Esta é a base para inferência probabilística em IA.

Regra de Bayes: Formulação Geral

- A formulação clássica para a equação de Bayes é

Equação de Bayes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

- Formulação alternativa, considerando múltiplas evidências e:

$$P(Y|X, e) = \frac{P(X|Y, e)P(Y | e)}{P(X | e)}$$

Aplicação prática da equação de Bayes

- Muitas vezes, percebemos como evidência o efeito de alguma causa desconhecida e gostaríamos de determinar essa causa.
- reformulando a equação de Bayes para atender essa demanda temos:

Equação de Bayes – Causa e Efeito

$$P(Causa|Efeito) = \frac{P(Efeito|Causa)P(Causa)}{P(Efeito)}$$

- A probabilidade condicional $P(Efeito|Causa)$ quantifica a relação na direção **causal**, enquanto $P(Causa|Efeito)$ descreve a direção **diagnóstica**.
- Em tarefas como **diagnóstico**, normalmente temos probabilidades condicionais de relações causais. O médico sabe $P(Sintomas|Doena)$ e deseja obter um **diagnóstico**: $P(Doena|Sintomas)$.

Exemplo Clássico: Classificador de Spam

- Imagine que queremos construir um sistema que determine se um e-mail é spam ou não com base em suas palavras.
- O teorema de Bayes nos permite calcular a probabilidade de um e-mail ser spam dado que ele contém certas palavras, como "**ganhe dinheiro rápido**".
- Exemplo passo a passo — Suponha que:
 - A probabilidade de qualquer e-mail ser spam é $P(spam) = 0.3$ (30% dos e-mails são spam).
 - A probabilidade de um e-mail conter a frase "ganhe dinheiro rápido" dado que é spam é $P(ganhe\ dinheiro\ rápido \mid spam) = 0.8$.
 - A probabilidade de um e-mail conter essa frase mesmo sendo legítimo é $P(ganhe\ dinheiro\ rápido \mid \neg spam) = 0.1$.

Exemplo Clássico: Classificador de Spam

- Usando o teorema de Bayes:

$$P(\text{spam} \mid \text{ganhe dinheiro rápido}) = \frac{P(\text{ganhe dinheiro rápido} \mid \text{spam})P(\text{spam})}{P(\text{ganhe dinheiro rápido})}$$

- O denominador pode ser calculado com a regra da probabilidade total:

$$\begin{aligned} P(\text{ganhe dinheiro rápido}) &= P(\text{ganhe dinheiro rápido} \mid \text{spam})P(\text{spam}) + \\ &\quad + P(\text{ganhe dinheiro rápido} \mid \neg \text{spam})P(\neg \text{spam}) = \\ &= (0.8)(0.3) + (0.1)(0.7) = 0.24 + 0.07 = 0.31 \end{aligned}$$

- Agora aplicamos:

$$P(\text{spam} \mid \text{ganhe dinheiro rápido}) = \frac{0.8 \times 0.3}{0.31} = \frac{0.24}{0.31} \approx 0.774$$

Exemplo Clássico: Classificador de Spam

- Ou seja, há cerca de 77,4% de chance do e-mail ser spam se contiver essa frase.
- Esse raciocínio é a base do algoritmo *Naive Bayes*, amplamente usado em processamento de linguagem natural.
- O algoritmo *Naive Bayes* estende esse cálculo para múltiplas palavras, assumindo independência entre elas (daí o termo "**ingênuo**") para simplificar os cálculos.
- **Em resumo:** o **teorema de Bayes** permite que máquinas atualizem crenças com base em **evidências**, tornando-se essencial em IA para lidar com incerteza.

Exemplo médico: Diagnóstico

- Sintomas (efeito) \rightarrow Doença (causa)
- Exemplo: **meningite** causa **torcicolo** em 70% dos casos.
- Probabilidade de torcicolo em quem tem meningite: 0,7.
- Probabilidade de qualquer paciente ter meningite: ≈ 1 em 50.000.
- Probabilidade de qualquer paciente ter torcicolo: 1%.
- Seja s a proposição de que o paciente tenha torcicolo e m a probabilidade de o paciente tem meningite, temos

$$P(s \mid m) = 0.7$$

$$P(m) = \frac{1}{50000}$$

$$P(s) = 0.01$$

Exemplo médico: Diagnóstico

- Teremos então:

$$P(m | s) = \frac{P(s | m)P(m)}{P(s)} = \frac{0.7 \times 0.00002}{0.01} = 0.0014$$

- Ou seja, temos uma expectativa de que 0,14% dos pacientes com torcicolo tenham meningite.
- Note que, embora um torcicolo seja comum em pacientes com meningite (probabilidade de 0,7), a probabilidade de meningite em pacientes com torcicolo permanece pequena;
- Isso porque a probabilidade a priori de torcicolo (por qualquer causa) é muito maior do que a probabilidade *a priori* para meningite.

Regra de Bayes com normalização

- Podemos evitar a probabilidade *a priori* da evidência ($P(s)$ nesse caso), utilizando probabilidade *a posteriori* para cada variável em análise (aqui m e $\neg m$) e então, normalizar os resultados:

$$P(M|s) = \alpha \langle P(s | m)P(m), P(s | \neg m)P(\neg m) \rangle$$

- Para isso temos que estimar $P(s|\neg m)$ ao invés de $P(s)$. As vezes isso é mais fácil, as vezes é mais difícil.
- A forma geral da equação de Bayes com normalização é

$$P(Y | X) = \alpha P(X | Y)P(Y)$$

- onde α é a constante de normalização necessária para fazer $P(Y|X)$ somar 1.

Aplicando a regra de Bayes — Combinando evidências

- O que acontece quando temos mais de uma evidência?
- Por exemplo, o que um dentista pode concluir quando o paciente tem uma dor de dente e a sonda dele prende no dente do paciente?
- Da tabela de distribuições temos:

$$P(\text{Cavity} \mid \text{toothache} \wedge \text{catch}) = \alpha \langle 0.108, 0.016 \rangle \approx \langle 0.871, 0.129 \rangle$$

- Podemos usar a regra de Bayes para reformular o problema:

$$P(\text{Cavity} \mid \text{toothache} \wedge \text{catch}) = \alpha P(\text{toothache} \wedge \text{catch}) P(\text{Cavity})$$

Aplicando a regra de Bayes — Combinando evidências

- Para essa reformulação funcionar, precisamos saber a probabilidade condicional da conjunção *toothache* \wedge *catch* para cada valor de *Cavity*.
- Se houver n possíveis variáveis de evidência (raios X, dieta, higiene oral, etc.), então há $O(2^n)$ combinações possíveis de valores observados para os quais precisaríamos conhecer probabilidades condicionais.
- Para progredir, precisamos encontrar algumas afirmações adicionais sobre o domínio que permitam simplificar as expressões.

Aplicando a regra de Bayes — Combinando evidências

- Seria bom se *Toothache* e *Catch* fossem independentes, mas eles não são: Se a sonda prender no dente, é possível que exista uma cárie e que essa cárie cause a dor de dente;
- Essas variáveis são independentes, no entanto, dado a presença ou ausência de uma cárie;
- Cada um é causado diretamente pela cárie, mas não tem efeito direto um no outro: a dor de dente depende do estado dos nervos no dente, e a precisão da sonda depende principalmente da habilidade do dentista, ao qual a dor de dente é irrelevante.

Aplicando a regra de Bayes — Combinando evidências

- Matematicamente temos:

$$P(\text{toothache} \wedge \text{catch} \mid \text{Cavity}) = P(\text{toothache} \mid \text{Cavity})P(\text{catch} \mid \text{Cavity})$$

- Esta equação expressa a independência condicional da dor de dente e da sonda prender na cavidade da cárie.
- Podemos então chegar a:

$$P(\text{Cavity} \mid \text{toothache} \wedge \text{catch}) = P(\text{toothache} \mid \text{Cavity})P(\text{catch} \mid \text{Cavity})P(\text{Cavity})$$

- Agora, os requisitos das informações são os mesmos da inferência, usando cada pedaço de evidência separadamente.

- A definição geral de independência condicional de duas variáveis X e Y , dada uma terceira variável Z , é

Independência Condicional

$$P(X, Y \mid Z) = P(X \mid Z)P(Y \mid Z)$$

- no domínio odontológico teríamos:

$$P(\text{toothache}, \text{catch} \mid \text{Cavity}) = P(\text{toothache} \mid \text{Cavity})P(\text{catch} \mid \text{Cavity})$$

Modelo de Bayes Ingênuo (*Naive Bayes*)

- O exemplo odontológico ilustra um padrão de ocorrência comum em que uma única causa influencia diretamente uma série de efeitos, todos os quais são condicionalmente independentes, dado a causa (Causa única influencia múltiplos efeitos independentes condicionalmente).
- A distribuição conjunta completa pode ser escrita como

$$P(\text{Causa} \mid \text{Efeito}_1, \text{Efeito}_2, \dots) \propto P(\text{Causa}) \prod_i P(\text{Efeito}_i \mid \text{Causa})$$

- Tal distribuição de probabilidade é chamada de “ingênuo” porque muitas vezes é usada como uma **suposição simplificadora**;
- nos casos em que as variáveis de “efeito” não são estritamente independente dada a variável causa.

Modelo de Bayes Ingênuo (*Naive Bayes*)

- Na prática, sistemas ingênuos de Bayes geralmente funcionam muito bem, mesmo quando as condições de independência condicional não são estritamente verdadeiras.
- Para usar um modelo ingênuo de Bayes, podemos aplicar a equação anterior para obter a probabilidade de causa dado alguns efeitos observados.
- Chamaremos os efeitos observados de $E = e$, enquanto o restante das variáveis de efeito Y não são observadas.
- Dessa forma, temos

$$P(\text{Causa} \mid e) = \alpha \sum_y P(\text{Causa}, e, y)$$

Modelo de Bayes Ingênuo (*Naive Bayes*)

- O que nos leva a


$$\begin{aligned}P(Causa | e) &= \alpha \sum_y P(Causa) P(y | Causa) \left(\prod_j P(e_j | Causa) \right) \\&= \alpha P(Causa) \left(\prod_j P(e_j | Causa) \right) \sum_y P(y | Causa) \\&= \alpha P(Causa) \prod_j P(e_j | Causa)\end{aligned}$$

- Ou seja, para cada causa possível, multiplique a probabilidade a priori da causa pelo produto das probabilidades condicionais dos efeitos observados dada a causa e então normalize o resultado.

- Vamos retornar ao mundo de Wumpus mas agora vamos simplifica-lo e considerar apenas os poços (ignorar o Wumpus e o ouro);
- Vamos considerar um caso particular onde o agente visitou os quadrados $[1,1]$, $[1,2]$ e $[2,1]$;
- O agente sentiu uma brisa nos quadrados $[1,2]$ e $[2,1]$, ou seja não há mais quadrados seguros para entrar. O que fazer?
- O agente sabe que $[1,1]$ não contem poço e que a probabilidade de poço nos demais quadrados é 0,2.

Wumpus World Revisado

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1



- Queremos uma variável booleana $P_{i,j}$ que é verdadeira se o quadrado $[i,j]$ conter um poço;
- Também temos a variável booleana $B_{i,j}$ se o quadrado $[i,j]$ possuir brisa;
- O próximo passo é especificar a distribuição conjunta completa, $P(P_{1,1}, \dots, P_{4,4}, B_{1,1}, B_{1,2}, B_{2,1})$. Aplicando a regra do produto, temos

$$P(P_{1,1}, \dots, P_{4,4}, B_{1,1}, B_{1,2}, B_{2,1}) = P(B_{1,1}, B_{1,2}, B_{2,1} \mid P_{1,1}, \dots, P_{4,4})P(P_{1,1}, \dots, P_{4,4})$$

- e temos também

$$P(P_{1,1}, \dots, P_{4,4}) = \prod_{i,j=1,1}^{4,4} P(P_{i,j})$$

- Como visitamos os quadrados $[1,1]$, $[1,2]$ e $[2,1]$ e sentimos brisa nos quadrados $[1,2]$ e $[2,1]$ podemos criar duas proposições:

$$b = \neg b_{1,1} \wedge b_{1,2} \wedge b_{2,1}$$

- e também

$$known = \neg p_{1,1} \wedge \neg p_{1,2} \wedge \neg p_{2,1}$$

- Desejamos responder questões como $P(P_{1,3} \mid known, b)$ ou seja, qual a probabilidade de poço no quadrado $[1,3]$?

- Para responder essa questão, usamos a equação $P(X | e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$,
- Logo, temos:

$$P(P_{1,3} | \textit{known}, b) = \alpha \sum_{\textit{unknown}} P(P_{1,3}, \textit{known}, b, \textit{unknown})$$

- Vamos considerar os quadrados desconhecidos com *unknown*, os quadrados da *frontier* aqueles vizinhos aos visitados e os quadrados que são desconhecidos e não fazem parte da fronteira como *other*.

- Temos então:

$$\begin{aligned} & P(P_{1,3} \mid \textit{known}, b) \\ &= \alpha \sum_{\textit{unknown}} P(P_{1,3}, \textit{known}, b, \textit{unknown}) \\ &= \alpha \sum_{\textit{unknown}} P(b \mid P_{1,3}, \textit{known}, \textit{unknown}) P(P_{1,3}, \textit{known}, \textit{unknown}) \\ &= \alpha \sum_{\textit{frontier}} \sum_{\textit{other}} P(b \mid \textit{known}, P_{1,3}, \textit{frontier}, \textit{other}) P(P_{1,3}, \textit{known}, \textit{frontier}, \textit{other}) \\ &= \alpha \sum_{\textit{frontier}} \sum_{\textit{other}} P(b \mid \textit{known}, P_{1,3}, \textit{frontier}) P(P_{1,3}, \textit{known}, \textit{frontier}, \textit{other}), \end{aligned}$$

- Usando independência, o primeiro termo da expressão não depende de Other podemos mover o somatório para dentro:

$$P(P_{1,3} \mid \text{known}, b) = \alpha \sum_{\text{frontier}} P(b \mid \text{known}, P_{1,3}, \text{frontier}) \sum_{\text{other}} P(P_{1,3}, \text{known}, \text{frontier}, \text{other})$$

- Por independência, o termo a direita pode ser fatorado e então reorganizado

$$\begin{aligned} &P(P_{1,3} \mid \text{known}, b) \\ &= \alpha \sum_{\text{frontier}} P(b \mid \text{known}, P_{1,3}, \text{frontier}) \sum_{\text{other}} P(\text{known})P(\text{frontier})P(\text{other}) \\ &= \alpha P(\text{known})P(P_{1,3}) \sum_{\text{frontier}} P(b \mid \text{known}, P_{1,3}, \text{frontier})P(\text{frontier}) \sum_{\text{other}} P(\text{other}) \\ &= \alpha' P(P_{1,3}) \sum_{\text{frontier}} P(b \mid \text{known}, P_{1,3}, \text{frontier})P(\text{frontier}), \end{aligned}$$

Wumpus World Revisado

- Onde $P(\text{known})$ passou para a constante de normalização e $\sum_{\text{other}} P(\text{other}) = 1$.
- Observe que $P(b \mid \text{known}, P_{1,3}, \text{frontier})$ é 1 se brisa é consistente com as variáveis e 0 caso contrário;
- Temos então:




Figure 12.6 Consistent models for the frontier variables, $P_{2,2}$ and $P_{3,1}$, showing $P(\text{frontier})$ for each model: (a) three models with $P_{1,3} = \text{true}$ showing two or three pits, and (b) two models with $P_{1,3} = \text{false}$ showing one or two pits.

- O que nos leva a

$$P(P_{1,3} \mid \text{known}, b) = \alpha' \langle 0.2(0.04 + 0.16 + 0.16), 0.8(0.4 + 0.16) \rangle \approx \langle 0.31, 0.69 \rangle.$$

- O seja, $[1,3]$ contem um poço com probabilidade 0,31;
- De forma similar podemos chegar ao fato que o quadrado $[2,2]$ tem um poço com probabilidade 0,86.

- **Conceitos principais:**
 - independência;
 - produto;
 - equação de Bayes,
 - independência condicional,
 - Modelo Ingênuo de Bayes (Naive Bayes).
- Aplicações práticas em diagnóstico, processamento de linguagem natural, visão robótica, agentes inteligentes, inferência probabilística.
- Limitações dos modelos ingênuos e avanços atuais.

- Em quais contextos a independência condicional é razoável?
- Como modelos probabilísticos podem melhorar diagnósticos médicos?
- Exemplos no nosso cotidiano onde usamos inferência bayesiana sem perceber.

- Russell, S. J., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. 4^a ed.
- Slides oficiais: *aima.cs.berkeley.edu*
- Outros: materiais complementares em IA.

Obrigado!

E-mail: fabiano-soares@unb.br

LinkedIn: <https://www.linkedin.com/in/fabiano-soares-06b6a821a/>

Site do curso: <https://www.fabiano-soares.eng.br/fga0221-inteligência-artificial>