

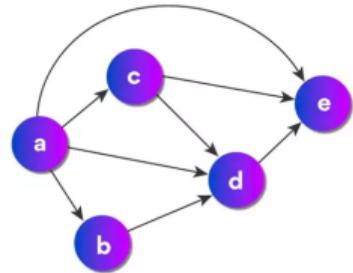
Parte III: IA e Incerteza.

Prof. Fabiano Araujo Soares, Dr. / FGA 0221 - Inteligência Artificial

Universidade de Brasília

2025





Como um sistema de IA pode tomar decisões confiáveis em ambientes incertos mesmo quando as evidências são imprecisas ou parciais?

Redes Bayesianas são a resposta: elas combinam conhecimento causal com dados observados para calcular racionalmente o que é mais provável, permitindo que máquinas “raciocinem sob incerteza”.

Motivação: Por que Redes Bayesianas?

- Em IA e Engenharia, poucas situações têm informação completa ou livre de ruído: incerteza é a regra.
- Modelos como o Naive Bayes simplificam suposições (independência total entre variáveis) — o que raramente é realista.
- Precisamos representar relações de dependência e independência condicional de forma compacta e interpretável.
- Redes Bayesianas oferecem um grafo probabilístico que combina intuição visual e base matemática sólida.
- Permitem atualizar crenças à medida que novas evidências chegam (raciocínio probabilístico dinâmico).

Usos marcantes:

- Diagnóstico médico assistido por computador (p.ex., avaliação de sintomas para doenças raras);
- Planejamento e tomada de decisão em sistemas autônomos (robótica, veículos inteligentes);
- Análise de causas em engenharia de falhas e segurança;
- Sistemas de recomendação sensíveis a contexto.

Redes Bayesianas: Vantagem chave

Representação **compacta** e **interpretável** de distribuições conjuntas de alta dimensionalidade.



O que é uma Rede Bayesiana?

- Um grafo dirigido acíclico (DAG) em que cada nó representa uma variável aleatória (discreta ou contínua).
- As arestas (setas) indicam dependências diretas: se há uma seta de A para B , então A é um *pai* de B e influencia sua distribuição.
- A ausência de ciclos garante que não haja dependências circulares — o que é essencial para a consistência probabilística.
- Cada variável tem uma Tabela de Probabilidade Condicional (CPT) que especifica $P(X_i | Pais(X_i))$.
- A estrutura do grafo codifica independências condicionais: duas variáveis são independentes dado um conjunto de evidências se forem d-separadas no grafo.

Fatoração da Distribuição Conjunta

Princípio fundamental:

A distribuição conjunta de todas as variáveis X_1, X_2, \dots, X_n pode ser decomposta como:

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | \text{Pais}(X_i))$$

onde $\text{Pais}(X_i)$ são os nós que têm arestas apontando para X_i .

Fatoração da Distribuição Conjunta (cont.)

Exemplo: Diagnóstico médico

Variáveis: D (Doença), S (Sintoma), E (Exame).

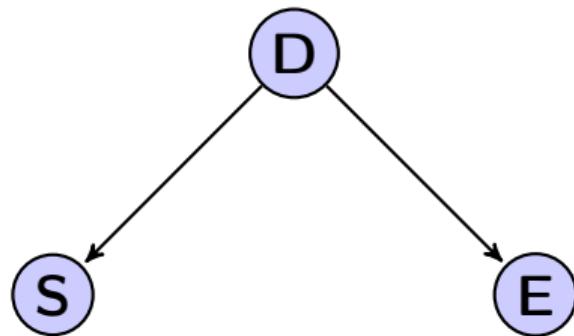
Estrutura: $D \rightarrow S$, $D \rightarrow E$

$$P(D, S, E) = P(D) \cdot P(S | D) \cdot P(E | D)$$

- Sem a rede, precisaríamos de $2^3 - 1 = 7$ parâmetros (para 3 variáveis binárias).
- Com a rede, apenas: 1 (para D) + 2 (para $S | D$) + 2 (para $E | D$) = 5.

A fatoração reduz complexidade e facilita inferência!

Interpretação do Diagrama: Diagnóstico Médico



- **Nó D (Doença):** variável raiz, representa a causa subjacente.
- **Nó S (Sintoma):** depende de D — pacientes com a doença têm maior probabilidade de apresentar o sintoma.
- **Nó E (Exame):** depende de D — o resultado do exame é influenciado pela presença da doença.
- **Ausência de aresta entre S e E :** dado D , o sintoma e o exame são condicionalmente independentes.
 - Ou seja: se sabemos o estado da doença, saber o sintoma não muda nossa crença sobre o exame (e vice-versa).

Implicação probabilística

A estrutura implica:

$$P(S, E | D) = P(S | D) \cdot P(E | D)$$

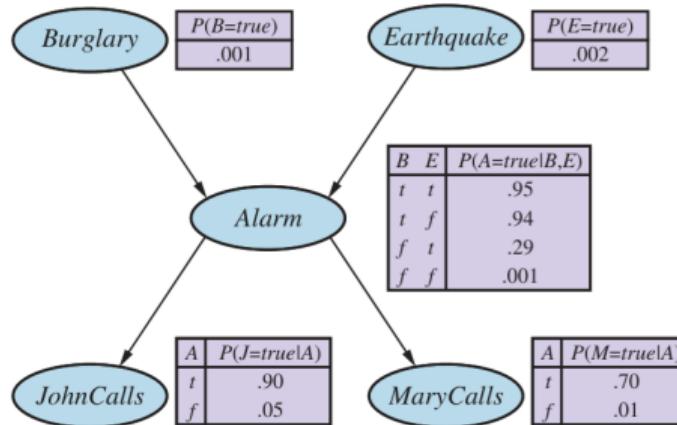
Essa independência condicional é o que permite a fatoração eficiente da distribuição conjunta.

Exemplo: Alarme de Roubo (Russell & Norvig)

- Um morador de LA (Bruce) comprou um novo sistema antirroubo que detecta tentativas de invasão de forma bastante eficaz mas dispara as vezes quando terremotos ocorrem;
- Bruce tem dois vizinhos Mary e John que prometeram telefonar para ele caso o alarme acione;
- John quase sempre liga quando escuta o alarme, mas às vezes confunde o telefone tocando com o alarme e liga também;
- Mary, por outro lado, gosta de música alta e muitas vezes não escuta o alarme.
- Dada a evidência de quem ligou ou não, gostaríamos de estimar a probabilidade de um roubo.

Exemplo: Alarme de Roubo (Russell & Norvig)

- Variáveis: Roubo (B), Terremoto (E), Alarme (A), JohnLiga (J), MaryLiga (M)
- CPTs baseadas em conhecimento causal



Fatoração:

$$P(B, E, A, J, M) = P(B)P(E)P(A | B, E)P(J | A)P(M | A)$$

Independência Condicional

- Em uma Rede Bayesiana, a estrutura do grafo codifica relações de dependência e independência entre variáveis.
- Regra central: Cada nó (variável) é condicionalmente independente de todos os seus não-descendentes, dadas as variáveis que são seus pais.
- Formalmente: Se X é um nó e $Pa(X)$ seus pais, então X é independente dos não-descendentes dados $Pa(X)$.
- Isso simplifica a descrição da distribuição conjunta e reduz o número de parâmetros.

Independência Condicional

- Em uma Rede Bayesiana, a estrutura do grafo codifica relações de dependência e independência entre variáveis.
- Regra central: Cada nó (variável) é condicionalmente independente de todos os seus não-descendentes, dadas as variáveis que são seus pais.
- Formalmente: Se X é um nó e $Pa(X)$ seus pais, então X é independente dos não-descendentes dados $Pa(X)$.
- Isso simplifica a descrição da distribuição conjunta e reduz o número de parâmetros.

Exemplo:

$$P(J, M | A) = P(J | A) \cdot P(M | A)$$

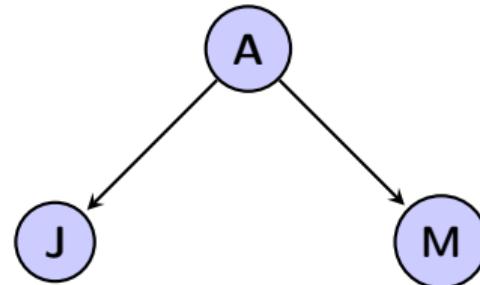
Dado o alarme A , João (J) e Maria (M) tornam-se independentes.

Independência Condicional

- Estrutura do grafo codifica independências: cada variável é independente dos não-descendentes dado seus pais.
- Formalmente: se X é um nó e $Pa(X)$ seus pais, então $X \perp\!\!\!\perp$ não-descendentes dado $Pa(X)$ (X é condicionalmente independente de seus não-descendentes dado $Pa(X)$).
- Facilita a fatoração da distribuição conjunta.

Exemplo:

$$P(J, M | A) = P(J | A) \cdot P(M | A)$$



Bloco (Cobertura) de Markov

- O bloco de Markov de um nó X em uma Rede Bayesiana é formado por:
 - Os pais de X
 - Os filhos de X
 - Os demais pais dos filhos de X
- Se condicionarmos sobre o bloco de Markov de X , então X se torna independente do restante da rede.
- Usado para construir algoritmos eficientes de inferência e de amostragem (Gibbs Sampling, etc).

Bloco (Cobertura) de Markov

- O bloco de Markov de um nó X em uma Rede Bayesiana é formado por:
 - Os pais de X
 - Os filhos de X
 - Os demais pais dos filhos de X
- Se condicionarmos sobre o bloco de Markov de X , então X se torna independente do restante da rede.
- Usado para construir algoritmos eficientes de inferência e de amostragem (Gibbs Sampling, etc).

Exemplo:

- No problema do alarme, o bloco de Markov do nó A é $\{R, T, J, M\}$ (Roubo, Terremoto, JoãoLiga, MariaLiga).
- Condicionando $(A | R, T, J, M)$, A é independente dos outros nós da rede.

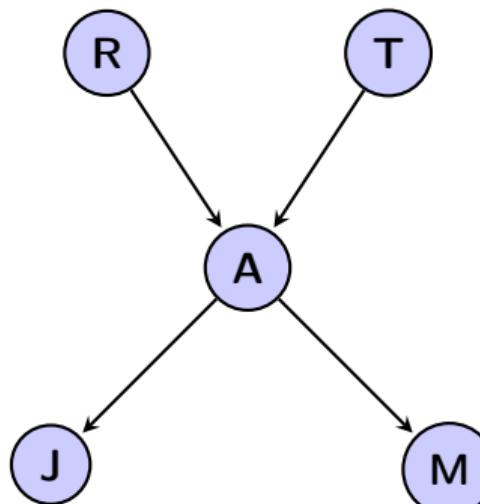
Bloco de Markov (Cobertura de Markov)

- O bloco de Markov de um nó X é o conjunto formado por seus pais, filhos e os outros pais dos seus filhos.
- Condicionando no bloco de Markov, X é independente do restante da rede.
- Isso é fundamental para algoritmos de inferência local (ex: Gibbs Sampling).

Exemplo no problema do alarme: O bloco de Markov do nó A é:

$$\{R, T, J, M\}$$

onde R =Roubo, T =Terremoto, J =João Liga, M =Maria Liga.



d-separação

- A **d-separação** é um critério gráfico que determina se dois conjuntos de variáveis são condicionalmente independentes em um DAG.
- Um conjunto Z d-separa X de Y se todos os caminhos entre X e Y são bloqueados por Z , segundo regras específicas:
 - Caminhos de "caso causal" (\rightarrow) ou "caso comum" (\leftarrow) são bloqueados se o nó intermediário está em Z .
 - Caminhos "caso v-estrutural" ($\rightarrow V \leftarrow$) só ficam bloqueados se nem o nó v-estrutural nem seus descendentes estão em Z .
- d-separação permite identificar independências e orientar inferências eficientes.

d-separação

- A **d-separação** é um critério gráfico que determina se dois conjuntos de variáveis são condicionalmente independentes em um DAG.
- Um conjunto Z d-separa X de Y se todos os caminhos entre X e Y são bloqueados por Z , segundo regras específicas:
 - Caminhos de "caso causal" (\rightarrow) ou "caso comum" (\leftarrow) são bloqueados se o nó intermediário está em Z .
 - Caminhos "caso v-estrutural" ($\rightarrow V \leftarrow$) só ficam bloqueados se nem o nó v-estrutural nem seus descendentes estão em Z .
- d-separação permite identificar independências e orientar inferências eficientes.

Exemplo:

- No alarme: J (JoãoLiga) e M (MariaLiga) são d-separados se condicionarmos em A (Alarme).
- Portanto, $P(J, M | A) = P(J | A) \cdot P(M | A)$.

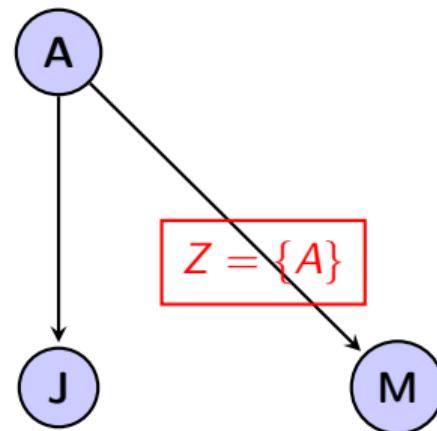
d-separação

- d-separação é um critério para determinar independência condicional em grafos dirigidos acíclicos.
- Um caminho é bloqueado por um conjunto de nós Z se atende às regras:
 - **Caminhos em cadeia** ($X \rightarrow Y \rightarrow Z$) e **forks** ($X \leftarrow Y \rightarrow Z$) são bloqueados se o nó intermediário está em Z .
 - **V-estruturas** ($X \rightarrow Y \leftarrow Z$) são bloqueadas **somente se Y não está em Z e nem nenhum de seus descendentes**.
- Se todos os caminhos entre X e Y são bloqueados por Z , então $X \perp\!\!\!\perp Y | Z$.

d-separação (cont.)

Exemplo: No problema do alarme, J e M são d-separados dado A . Isso implica:

$$P(J, M | A) = P(J | A) \cdot P(M | A)$$



Resumindo: Bloco de Markov e d-separação

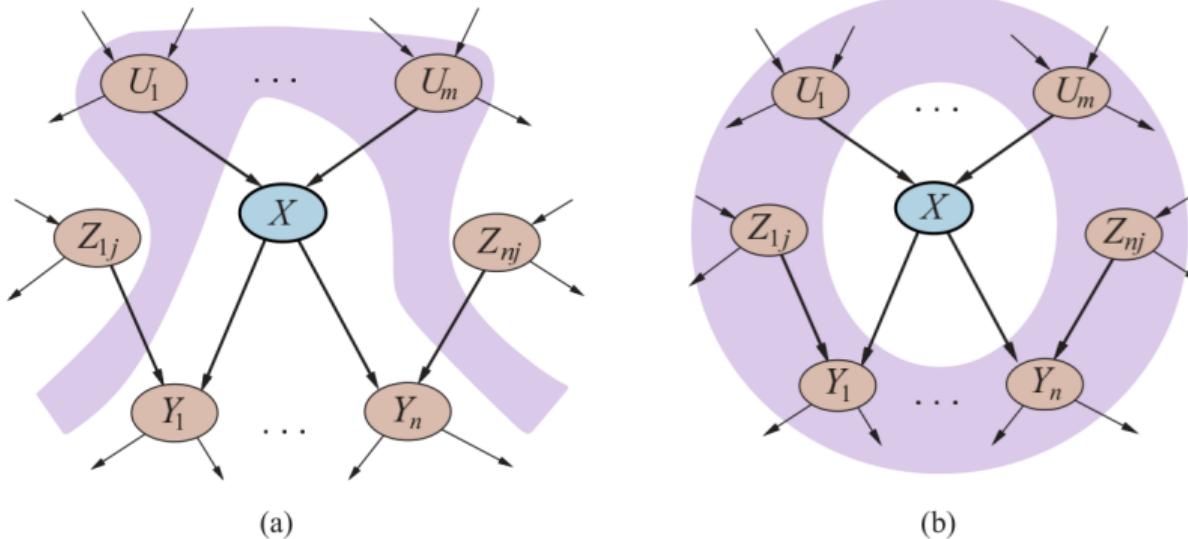


Figure 13.4 (a) A node X is conditionally independent of its non-descendants (e.g., the Z_{ij} s) given its parents (the U_i s shown in the gray area). (b) A node X is conditionally independent of all other nodes in the network given its Markov blanket (the gray area).

- ① **Discretização:** Dividir os valores possíveis em intervalos fixos, por exemplo, faixas de temperatura ($< 0^{\circ}\text{C}$, $0^{\circ}\text{C} - 100^{\circ}\text{C}$, e $> 100^{\circ}\text{C}$);
- ② **Distribuições probabilísticas:** Outra abordagem é definir uma variável contínua usando uma das famílias padrão de funções de densidade de probabilidade, como a distribuição Gaussiana $N(x; \sigma^2)$;
- ③ **Não paramétrica:** Define a distribuição condicional implicitamente com uma coleção de instâncias, cada uma contendo valores das variáveis genitoras e filho.

Redes Bayesianas com variáveis contínuas — Exemplo

- Redes Bayesianas que possuem variáveis discretas e contínuas são chamadas de **Redes Bayesianas Híbridas**;

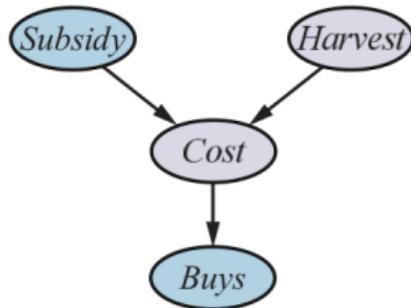


Figure 13.6 A simple network with discrete variables (*Subsidy* and *Buys*) and continuous variables (*Harvest* and *Cost*).

Redes Bayesianas com variáveis contínuas

- Para lidar com redes hibridas, precisamos aprender a converter variáveis genitoras contínuas em variáveis filhos discretas e vice versa;
- Para trazer a informação de genitores discretos em filhos contínuos podemos utilizar estratégias como **distribuição condicional linear-gaussiana** em que o filho tem uma distribuição gaussiana cuja média μ varia linearmente com o valor do genitor e cujo desvio padrão σ é fixo.
- Para trazer informações de genitores contínuos em filhos discretos podemos usar funções de limiarização como a integral da distribuição normal até o valor x ;

Inferência: O que é e por que importa?

- O objetivo da inferência é calcular **probabilidades *a posteriori*** de variáveis de interesse, dadas evidências observadas.
- Exemplo: dado que Maria ligou ($M = V$), qual é a probabilidade de haver um roubo ($R = V$)?

$$P(R = V \mid M = V)$$

- Isso envolve atualizar crenças usando a regra de Bayes e a estrutura da rede.
- Tipos comuns de consultas:
 - **Diagnóstico:** $P(\text{causa} \mid \text{efeito})$
 - **Predição:** $P(\text{efeito} \mid \text{causa})$
 - **Explicação mais provável (MAP):** qual configuração de variáveis explica melhor as evidências?
- A estrutura do grafo permite computar essas probabilidades de forma eficiente — sem precisar da tabela completa.

Inferência Exata: Explorando a Estrutura

- **Eliminação de Variáveis:**
 - Algoritmo que calcula $P(X | E)$ somando variáveis não relevantes na ordem certa.
 - Usa a fatoração da rede: $P(X_1, \dots, X_n) = \prod_i P(X_i | \text{Pais}(X_i))$.
 - Ordem de eliminação afeta eficiência — ideal: minimizar tamanho dos fatores intermediários.
- **Propagação em Árvore de Cliques (Clique Tree):**
 - Transforma a rede em uma árvore de cliques (super nós com variáveis agrupadas).
 - Permite inferência eficiente via troca de mensagens entre cliques.
 - Ideal para múltiplas consultas: a estrutura é pré-compilada.
- **Complexidade:** exponencial na *treewidth* da rede, mas viável para redes esparsas ou com estrutura de árvore.

Inferência Exata: Exemplo

- Vamos retornar ao exemplo do **alarme contra roubo**. Poderíamos perguntar a probabilidade de um roubo dado que **John ligou e Mary ligou**:

$$P(\text{Burglary} \mid \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true}) = \langle 0.284, 0.716 \rangle$$

- uma consulta do tipo $P(X \mid \mathbf{e})$ pode ser respondida como:

$$P(X \mid \mathbf{e}) = \alpha P(X \wedge \mathbf{e}) = \alpha \sum_{\mathbf{y}} P(X \wedge \mathbf{e} \wedge \mathbf{y})$$

onde \mathbf{y} são todas as combinações possíveis de valores das variáveis não observadas \mathbf{Y} .

- Uma rede Bayesiana fornece uma representação da distribuição conjunta completa.
- Temos que os termos $P(x, \mathbf{e}, \mathbf{y})$ na distribuição conjunta podem ser escritos como produtos de probabilidades condicionais da rede.

Inferência Exata: Exemplo

- Portanto, uma consulta pode ser respondida usando uma rede Bayesiana calculando somas de produtos de probabilidades condicionais da rede.
- Por exemplo, considere a consulta:

$$P(\text{Burglary} \mid \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true}).$$

- As variáveis ocultas para esta consulta são **Earthquake** (e) e **Alarm** (a). Temos então:
$$P(B \mid j, m) = \alpha P(B, j, m) = \alpha \sum_e \sum_a P(B, j, m, e, a)$$

Inferência Exata: Exemplo

- A semântica das redes de Bayes nos dá então uma expressão em termos das entradas CPT. Para simplificar, fazemos isso apenas para *Burglary = true*:

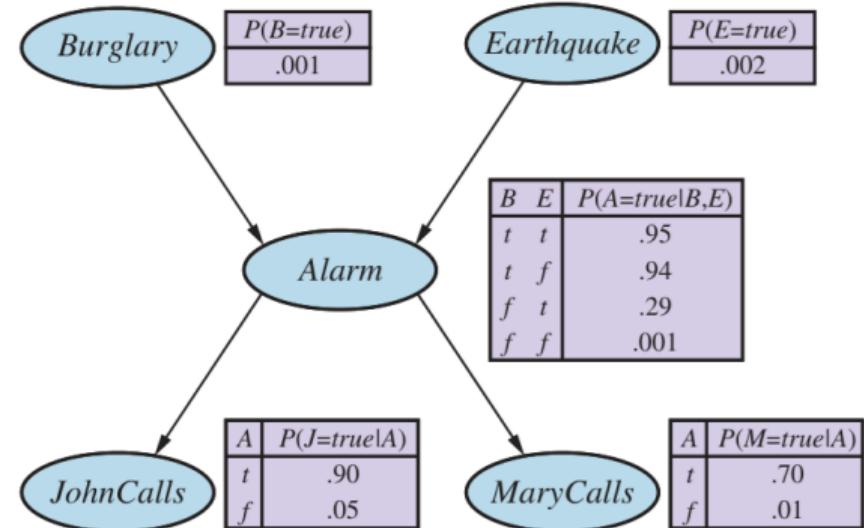
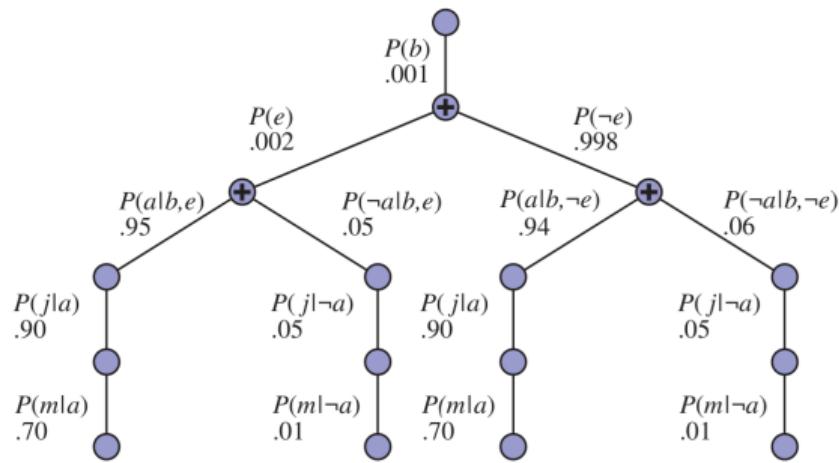
$$P(B | j, m) = \alpha \sum_e \sum_a P(b)P(e)P(a | b, e)P(j | a)P(m | a).$$

- Para simplificar o esforço computacional, podemos tirar do somatório as variáveis que não dependem das variáveis do somatório em questão:

$$P(B | j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a | b, e)P(j | a)P(m | a).$$

- Esta expressão pode ser avaliada percorrendo as variáveis em ordem, multiplicando entradas CPT à medida que avançamos.
- Para cada soma, também precisamos fazer um loop sobre os valores possíveis da variável.

Inferência Exata: Graficamente



Inferência Exata: Exemplo

- Dessa forma obtemos

$$P(B | j, m) = \alpha 0.00059224.$$

- E ainda, considerando a probabilidade de não-roubo:

$$P(B | j, m) = \alpha \langle 0.00059224, 0.0014919 \rangle \approx \langle 0.284, 0.716 \rangle.$$

- Ou seja, a chance de um roubo, dadas as ligações de ambos os vizinhos, é de cerca de 28%.

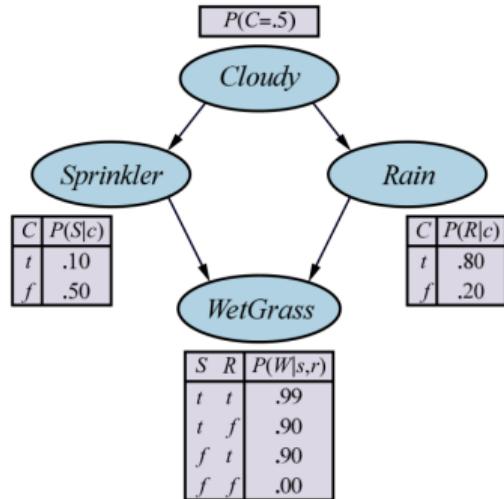
Inferência Exata: Conclusões

- Infelizmente a complexidade para uma rede Bayesiana com n variáveis ainda é alta $O(2^n)$;
- A título de comparação, uma rede como a do seguro de carro precisaria de 227 milhões de operações aritméticas para uma consulta;
- No entanto, se olharmos para a árvore anterior, podemos ver que existem expressões repetidas, como os produtos $P(j | a)P(m | a)$ e $P(j | \neg a)P(m | \neg a)$;
- A chave para uma inferência eficiente em redes Bayesianas é evitar tais cálculos repetidos.
- Para grandes redes, calcular a inferência exata é intratável.

Inferência Aproximada: Quando a exata é inviável

- Para redes grandes ou com alta conectividade, métodos exatos tornam-se impraticáveis.
- **Amostragem (Sampling):**
 - Gera amostras da distribuição conjunta (ex: *Prior Sampling*, *Rejection Sampling*).
 - Estima probabilidades por frequência relativa.
- **MCMC (Markov Chain Monte Carlo):**
 - Ex: *Gibbs Sampling* — atualiza uma variável por vez, condicionada ao resto.
 - Converge para a distribuição correta, mesmo sem conhecer a normalização.
 - Muito usado em redes com muitos ciclos ou evidências complexas.
- **Vantagem:** escalabilidade.
- **Desvantagem:** resultados são estimativas, com erro que diminui com mais amostras.

Inferência Aproximada: Exemplo — Método de amostragem direta



function PRIOR-SAMPLE(bn) **returns** an event sampled from the prior specified by bn
inputs: bn , a Bayesian network specifying joint distribution $\mathbf{P}(X_1, \dots, X_n)$

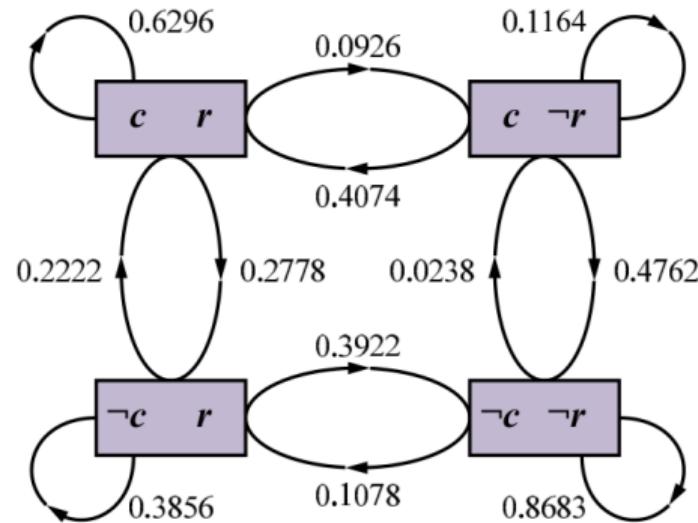
```
 $\mathbf{x} \leftarrow$  an event with  $n$  elements  
for each variable  $X_i$  in  $X_1, \dots, X_n$  do  
     $\mathbf{x}[i] \leftarrow$  a random sample from  $\mathbf{P}(X_i | \text{parents}(X_i))$   
return  $\mathbf{x}$ 
```

Inferência Aproximada: Exemplo — Método de amostragem direta

- ① Amostra de $P(Cloudy) = \langle 0.5, 0.5 \rangle$, valor é **true**.
 - ② Amostra de $P(Sprinkler | Cloudy = true) = \langle 0.1, 0.9 \rangle$, valor é **false**.
 - ③ Amostra de $P(Rain | Cloudy = true) = \langle 0.8, 0.2 \rangle$, valor é **true**.
 - ④ Amostra de $P(WetGrass | Sprinkler = false, Rain = true) = \langle 0.9, 0.1 \rangle$, valor é **true**.
- Nesse caso, a amostra retornada pelo algoritmo seria **[true,false,true,true]**.

Inferência Aproximada: Exemplo — Cadeia de Markov Monte Carlo

- **Cadeia de Markov Monte Carlo (MCMC):** Em vez de gerar cada amostra do zero, os algoritmos MCMC geram uma amostra fazendo uma alteração aleatória na amostra anterior.



- Dada a estrutura da rede, o objetivo é estimar as **Tabelas de Probabilidade Condicional (CPTs)** a partir de dados.
- **Dados completos** (todas as variáveis observadas):
 - Estimativa direta por **contagem de frequências**.
 - Ex: $P(S = V | D = V) = \frac{\text{número de casos com } S=V, D=V}{\text{número de casos com } D=V}$
 - Pode-se usar **apriori de Dirichlet** (suavização de Laplace) para evitar probabilidades zero.
- **Dados incompletos** (variáveis ocultas ou faltantes):
 - Não é possível contar diretamente.
 - Usa-se o algoritmo **EM (Expectation-Maximization)**:
 - **E-step:** Estima valores esperados das variáveis ocultas dadas as evidências e os parâmetros atuais.
 - **M-step:** Atualiza os parâmetros maximizando a verossimilhança esperada.
 - Itera até convergência.

Algoritmo EM: E-step e M-step Explicados

Objetivo: Estimar parâmetros quando há **variáveis ocultas** (ex: D não observada).

Exemplo: Rede $D \rightarrow S$, com dados apenas de S : Caso 1 2 3 4 5
 $\begin{matrix} S \\ V \\ V \\ E \\ V \\ E \end{matrix}$

Parâmetros a estimar:

- $\theta = P(D = V)$
 - $\theta_1 = P(S = V \mid D = V)$
 - $\theta_0 = P(S = V \mid D = F)$

Importante: θ_1 e θ_0 são independentes — não precisam somar 1!

Inicialização:

- $\theta = 0.5$, $\theta_1 = 0.7$, $\theta_0 = 0.3$

E-step: Estimando Valores Esperados

Para cada caso, calculamos a **probabilidade esperada** de $D = V$ dado S , usando Bayes:

$$P(D = V | S) = \frac{P(S | D = V)P(D = V)}{P(S)}$$

Exemplo para Caso 1 ($S = V$):

$$P(D = V | S = V) = \frac{0.7 \times 0.5}{0.7 \times 0.5 + 0.3 \times 0.5} = \frac{0.35}{0.5} = 0.7$$

Repetimos para todos os casos → obtemos valores esperados de D .

Resultado do E-step: uma tabela com $E[D = V | S]$ para cada caso:

Caso	1	2	3	4	5
S	V	V	F	V	F
$E[D = V]$	0.7	0.7	0.3	0.7	0.3

M-step: Maximizando a Verossimilhança Esperada

Com os valores esperados do E-step, atualizamos os parâmetros:

1. $P(D = V)$:

$$\theta = \frac{\sum E[D = V]}{N} = \frac{0.7 + 0.7 + 0.3 + 0.7 + 0.3}{5} = 0.54$$

2. $P(S = V | D = V)$:

$$\theta_1 = \frac{\sum_{S=V} E[D = V]}{\sum E[D = V]} = \frac{0.7 + 0.7 + 0.7}{0.7 + 0.7 + 0.3 + 0.7 + 0.3} = \frac{2.1}{2.7} \approx 0.78$$

3. $P(S = V | D = F)$:

$$\theta_0 = \frac{\sum_{S=V} E[D = F]}{\sum E[D = F]} = \frac{(1 - 0.7) + (1 - 0.7) + (1 - 0.7)}{(1 - 0.7) + (1 - 0.7) + (1 - 0.3) + (1 - 0.7) + (1 - 0.3)} = \frac{0.9}{2.3} \approx 0.39$$

Próxima iteração: usar novos $\theta, \theta_1, \theta_0$ no E-step. **Convergência:** quando os parâmetros estabilizam.



Aprendizado de Estrutura

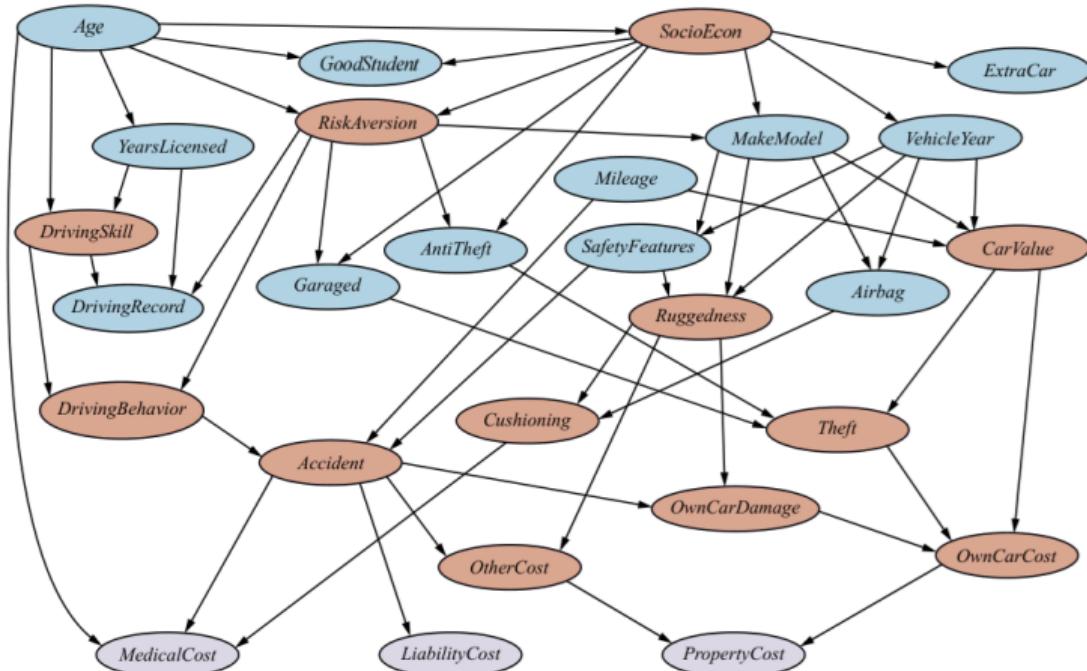
- Objetivo: descobrir a **estrutura do grafo** (quem influencia quem) a partir de dados.
- É um problema difícil: número de DAGs cresce exponencialmente com o número de variáveis.
- **Abordagem comum:** busca heurística no espaço de estruturas.
 - Começa com uma estrutura inicial (ex: vazia).
 - Aplica operações: adicionar, remover ou inverter arestas.
 - Usa uma **função de pontuação** para avaliar cada estrutura.
- **Critérios de pontuação:**
 - **MDL (Minimum Description Length)**: favorece modelos que comprimem bem os dados.
 - **AIC (Akaike Information Criterion)**: equilibra verossimilhança e número de parâmetros.
 - **BIC (Bayesian Information Criterion)**: similar ao AIC, mas com penalização mais forte para complexidade.
- **Algoritmo K2**: busca eficiente com ordem de nós pré-definida e prior uniforme.

Integração com Conhecimento de Domínio

- O aprendizado não precisa ser puramente baseado em dados.
- É comum **incorporar conhecimento de especialistas**:
 - Fixar certas arestas (ex: sabemos que $D \rightarrow S$).
 - Restringir a ordem dos nós (para algoritmos como K2).
 - Definir subestruturas conhecidas (ex: módulos funcionais).
- **Vantagens**:
 - Reduz espaço de busca.
 - Melhora interpretabilidade.
 - Corrige viés de dados escassos ou ruidosos.
- **Desafios**:
 - Conflito entre dados e conhecimento.
 - Dificuldade de elição de conhecimento.
- Em muitos casos, usa-se uma abordagem **híbrida**: estrutura parcialmente definida por especialistas, parâmetros aprendidos dos dados.

Rede Bayesiana: Exemplo Real

- Aqui está um exemplo de uma rede Bayesiana para decisão sobre seguro de automóvel.



- **Diagnóstico médico:** modelar incerteza entre doenças, sintomas e exames.
 - Exemplo clássico: **Pathfinder** — sistema para diagnóstico de doenças linfáticas.
 - Usava uma rede com 60+ variáveis e alcançou desempenho superior ao de especialistas.
- **Sistemas de apoio à decisão clínica:**
 - Ex: ajuste de **dosagem de insulina** em diabéticos.
 - Incorpora variáveis como glicemia, refeições, atividade física e histórico.
 - Atualiza recomendações com base em evidências observadas.
- **Vantagem:** interpretabilidade — médicos entendem o raciocínio probabilístico.

- **Controle de veículos autônomos:**

- Fusão de sensores (câmeras, LIDAR, radar) com incerteza.
- Inferência sobre estado do ambiente (ex: presença de pedestre) dado ruído nos dados.
- Decisões robustas mesmo com informações incompletas.

- **Modelagem de risco operacional (bancos e indústria):**

- Avaliação de falhas em processos, fraudes, falhas de sistemas.
- Combina dados históricos com conhecimento de especialistas.
- Ex: estimar probabilidade de falha em um sistema crítico.

- **Manutenção preditiva:**

- Prever falhas em equipamentos com base em sensores e histórico.
- Reduz custos e paradas não planejadas.

- **Tutores inteligentes e sistemas adaptativos de ensino:**
 - Modelam o conhecimento do aluno como variáveis ocultas.
 - Inferem o nível de domínio com base em respostas a exercícios.
 - Ex: se o aluno erra uma questão, a rede atualiza a crença sobre seus pontos fracos.
- **Personalização do aprendizado:**
 - Seleciona próximos tópicos ou exercícios com base na inferência.
 - Adapta ritmo e estilo conforme o perfil do aluno.
- **Vantagem:** combina modelagem cognitiva com incerteza — ideal para ambientes dinâmicos.
- **Exemplo real:** sistemas como *Bayesian Knowledge Tracing (BKT)* usados em plataformas educacionais.

Vantagens das Redes Bayesianas

- **Representação compacta de dependências probabilísticas:**
 - Reduz exponencialmente o número de parâmetros via independência condicional.
 - Ex: 10 variáveis binárias — sem estrutura: $2^{10} - 1 = 1023$ parâmetros; com rede esparsa: ~ 50 parâmetros.
- **Combinação natural de conhecimento *a priori* e aprendizado:**
 - Especialistas definem estrutura causal; dados refinam parâmetros.
 - Ex: médico define que Doença → Sintoma; dados estimam $P(\text{Sintoma} | \text{Doença})$.
- **Capacidade de inferência bidirecional e explicável:**
 - Diagnóstico: $P(\text{causa} | \text{efeito})$ e predição: $P(\text{efeito} | \text{causa})$.
 - **Transparência:** cada decisão é justificada por cálculos probabilísticos interpretáveis.
 - Crucial em aplicações críticas (saúde, segurança).
- **Robustez à incerteza:** lida naturalmente com dados incompletos, ruído e ambiguidade.

Limitações e Desafios

- Dificuldade na elicitação de CPTs para muitos nós/pais:
 - Um nó com k pais binários requer 2^k probabilidades condicionais.
 - Ex: se X tem 5 pais binários, são $2^5 = 32$ valores para $P(X | \text{pais})$.
 - Cresce exponencialmente — inviável para especialistas especificarem manualmente.
- Inferência exata inviável para topologias densas:
 - Complexidade é exponencial na *treewidth* da rede.
 - Redes com muitos ciclos ou alta conectividade exigem métodos aproximados.
 - Trade-off: precisão vs. eficiência computacional.
- Estrutura causal difícil de descobrir automaticamente:
 - Dados apenas observacionais não distinguem causalidade de correlação.
 - Grafos equivalentes (mesmo ajuste aos dados, estruturas diferentes).
 - Necessita conhecimento de domínio ou dados experimentais.
- Suposição de independência condicional pode ser restritiva em domínios complexos.

Redes Bayesianas vs. Outras Abordagens

Critério	Redes Bayesianas	Redes Neurais	Árvores de Decisão
Interpretabilidade	Alta	Baixa	Alta
Robustez à incerteza	Alta	Média	Baixa
Eficiência com poucos dados	Alta	Baixa	Média
Escalabilidade	Limitada	Alta	Média
Conhecimento prévio	Facilita	Dificulta	Média

Conclusão: Redes Bayesianas são ideais quando *interpretabilidade, robustez à incerteza e integração de conhecimento prévio* são prioritárias.

Referências

- Russell, S., Norvig, P. Artificial Intelligence: A Modern Approach, Cap. 14
- Heckerman, D. "A tutorial on learning with Bayesian networks", (arXiv:2002.00269)
- Pearl, J. "Probabilistic Reasoning in Intelligent Systems", 1988
- Slide decks: Poupart (UW), Conati (UBC), Lecture121.pdf

Obrigado!

E-mail: fabianosoares@unb.br

LinkedIn: <https://www.linkedin.com/in/fabiano-soares-06b6a821a/>

Site do curso: <https://www.fabianosoares.eng.br/fga0221-inteligencia-artificial>