


## Parte IV: Aprendizado de Máquina.

Prof. Fabiano Araujo Soares, Dr. / FGA 0221 - Inteligência Artificial

Universidade de Brasília

2025



Como conseguimos ensinar uma máquina a distinguir um e-mail legítimo de um spam, ou prever o preço de uma casa para venda, utilizando apenas exemplos do passado?



Como conseguimos ensinar uma máquina a distinguir um e-mail legítimo de um spam, ou prever o preço de uma casa para venda, utilizando apenas exemplos do passado?

O aprendizado supervisionado é o elo entre a experiência acumulada nos dados e a capacidade das máquinas de tomar decisões acertadas.

# Introdução ao Aprendizado Supervisionado

- Aprendizado supervisionado é um dos tipos mais comuns de aprendizado de máquina.
- O agente aprende a partir de dados rotulados, ou seja, exemplos de entrada com a saída desejada associada.
- O objetivo é aprender uma função que, dada uma nova entrada, prediz a saída correta.

# Características do Aprendizado Supervisionado

- Baseia-se em conjuntos de dados de treinamento contendo pares **entrada-saída**, onde cada entrada está associada à resposta correta.
- Engloba problemas de **classificação** (saída discreta, como categorias ou rótulos) e **regressão** (saída contínua, como valores numéricos).
- A qualidade, quantidade e representatividade dos dados rotulados são cruciais para que o modelo aprenda padrões generalizáveis e obtenha bom desempenho.
- Modelos treinados podem ser usados para prever resultados em novos dados não vistos durante o treinamento.
- Exige cuidado para evitar problemas como *overfitting* (quando o modelo se ajusta demais aos dados de treinamento) e *underfitting* (quando não captura padrões relevantes).

# Exemplos Práticos de Aprendizado Supervisionado

- **Identificação de e-mails como spam ou legítimos:** classificação automática para filtrar conteúdo indesejado.
- **Diagnóstico médico com base em exames:** modelos que auxiliam médicos a identificar doenças a partir de imagens ou dados clínicos.
- **Previsão de preços de imóveis:** estimativas de valores de mercado utilizando características históricas e atributos dos imóveis.
- **Reconhecimento facial e de voz:** sistemas que identificam pessoas e interpretam comandos por meio de voz, usados em segurança e assistentes virtuais.

# Aprendizado Supervisionado, como funciona?

- O modelo é treinado ajustando seus parâmetros para minimizar o erro nas previsões, usando dados rotulados como referência.
- Durante o treinamento, o algoritmo aprende a identificar padrões que relacionam entradas e saídas.
- Após o treinamento, o modelo pode generalizar e fazer previsões sobre dados novos e não vistos anteriormente.
- Para garantir a efetividade do modelo, técnicas como validação cruzada e divisão em conjuntos de treinamento, validação e teste são usadas.
- Métodos populares incluem **regressão linear**, **máquinas de vetores de suporte (SVM)**, **árvores de decisão** e **redes neurais**, usados conforme o tipo e complexidade do problema.

# Aprendizado Supervisionado, como funciona?

- Vamos descrever formalmente a tarefa de aprendizado supervisionado:
- Dado um conjunto de pares de dados de treinamento  $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$  onde cada par foi gerado por uma **função desconhecida**  $y = f(x)$  descubra uma **função hipótese**  $h(x)$  que aproxime a função  $f(x)$ .
- A função  $h$  é chamada de **hipótese** e é retirada de uma **classe de modelos**  $\mathcal{H}$  que pode ser, por exemplo, um conjunto de funções de 3º grau.



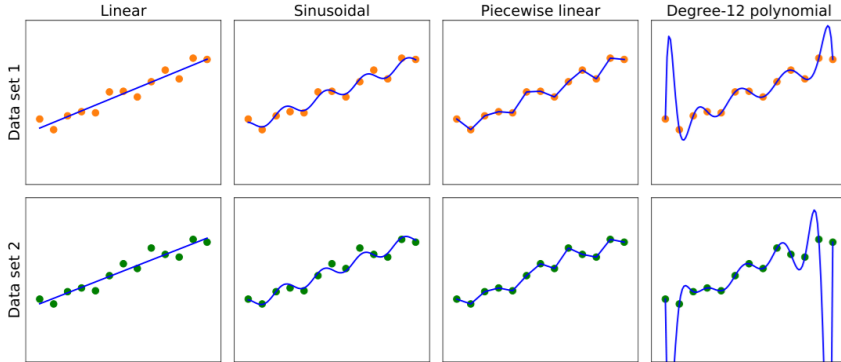
# Aprendizado Supervisionado, como funciona?

- Como escolhemos um espaço de hipóteses?
- Podemos ter algum conhecimento prévio (*a priori*) sobre o processo que gerou os dados.
- Podemos realizar uma análise exploratória de dados: examinando os dados com testes estatísticos e visualizações – histogramas, gráficos de dispersão, gráficos de caixa – buscando uma visão sobre qual espaço de hipótese pode ser apropriado.
- Ou podemos apenas tentar vários espaços de hipóteses e avaliar qual deles funciona melhor.

# Aprendizado Supervisionado, como funciona?

- Como escolhemos uma boa hipótese a partir do espaço de hipóteses?
- Para isso utilizamos um algoritmo buscando a função para a qual cada  $h(x_i)$  é próximo do valor  $y_i$ ;
- Desejamos uma hipótese Geral;
- Podemos avaliar se a hipótese é geral o suficiente com um segundo grupo de pares de amostras  $(x_i, y_i)$  que chamados de **conjunto de teste**.
- Dizemos que  $h$  generaliza bem se prediz com precisão as saídas do conjunto de teste.
- Idealmente, buscamos uma **hipótese consistente**, onde para cada  $x_i$  temos  $h(x_i) = y_i$ .

# Aprendizado Supervisionado – Cuidados






**Figure 19.1** Finding hypotheses to fit data. **Top row:** four plots of best-fit functions from four different hypothesis spaces trained on data set 1. **Bottom row:** the same four functions, but trained on a slightly different data set (sampled from the same  $f(x)$  function).

- Uma maneira de analisar os espaços de hipóteses é pelo **viés** (*bias*) que eles impõem (independentemente do conjunto de dados de treinamento) e a **variância** que eles produzem (de um conjunto de treinamento para outro).
- Por **viés** nos referimos a tendência de uma hipótese preditiva se desviar do valor esperado quando calculado a média em diferentes conjuntos de treinamento.
- Dizemos que uma hipótese é **sub-ajustada** (*underfitting*) quando não consegue encontrar um padrão nos dados de treinamento.

- Por **variância** nos referimos a quantidade de mudança na hipótese devido à flutuação na variação dos dados de treinamento.
- Dizemos que uma função está **super-ajustanda** (*overfitting*) aos dados quando presta muita atenção ao conjunto de dados de treinamento, fazendo com que ela tenha um desempenho ruim em dados não vistos.
- Buscamos sempre um compromisso entre viés e variância.

# Aprendizado Supervisionado – Cuidados



# Viés em Algoritmos de Aprendizado Supervisionado

- Dados desbalanceados ocorrem quando algumas classes aparecem muito mais que outras.
- Isso pode causar viés, levando o modelo a favorecer a classe majoritária.
- Resultados tendem a ser imprecisos ou injustos, especialmente para eventos raros.

# Técnicas para Mitigar Viés em Dados Desbalanceados

- **Reamostragem**

- *Oversampling*: aumentar artificialmente a classe minoritária.
- *Undersampling*: reduzir a classe majoritária.

- **Geração de Dados Sintéticos**

- Técnicas como SMOTE (*Synthetic Minority Over-sampling Technique*) criam exemplos artificiais na classe minoritária.

- **Ajuste de Pesos**

- Dar maior importância às classes minoritárias durante o treino.

- **Métricas Adequadas**

- Usar métricas como F1-score, matriz de confusão, AUC-ROC para avaliação justa.




- Sempre analisar a distribuição das classes antes do treinamento.
- Testar diferentes técnicas de balanceamento para encontrar a melhor para o problema.
- Validar modelos com conjuntos de teste representativos e métricas adequadas.
- Estar atento a possíveis impactos éticos e enviesamentos sociais.

## Primeiro exemplo – Flor de Íris

- Imagine que você quer classificar as espécies de flores de íris que sua avó possui em seu jardim;
- Você não é um botânico, no entanto, você possui um banco de dados sobre diferentes espécies de flores de íris feito por um botânico profissional;
- As espécies são:
  - Setosa (0);
  - Versicolor (1);
  - Virginica (2).

# Primeiro exemplo – Flor de Íris

- As características usadas para a classificação são:
  - Largura (width) da pétala.
  - Largura (width) da sépala.
  - Comprimento (length) da pétala.
  - Comprimento (length) da sépala.



- Aprendizado Supervisionado é um pilar essencial dentro do aprendizado de máquina, focado em ensinar modelos a partir de dados rotulados.
- Revisamos os principais conceitos e tipos de problemas (classificação e regressão).
- Discutimos os desafios práticos como viés e dados desbalanceados, e a importância da qualidade dos dados.
- Este conhecimento é fundamental para a construção de modelos precisos e robustos em diversas áreas.

# Principais Mensagens

- Dados rotulados de qualidade são a chave para o sucesso no aprendizado supervisionado.
- Escolher o algoritmo certo e aplicar técnicas para tratar desequilíbrios pode significar a diferença entre um modelo eficiente e um projeto falho.
- O entendimento desses princípios ajuda a criar soluções éticas e eficazes.

Na próxima aula, exploraremos os algoritmos de aprendizado supervisionado, entendendo suas técnicas e aplicações.

- Russell, S., Norvig, P., "Artificial Intelligence: A Modern Approach", 4th ed., Person, 2022.
- Duda, Richard O., "Pattern Classification", 2nd ed., Wiley, 2000.
- Muller, A. C., Guido, S., "Introduction to Machine Learning with Python A Guide for Data Scientists", O'Reilly, 2017.

# Obrigado!

E-mail: [fabiano-soares@unb.br](mailto:fabiano-soares@unb.br)

LinkedIn: <https://www.linkedin.com/in/fabiano-soares-06b6a821a/>

Site do curso: <https://www.fabiano-soares.eng.br/fga0221-inteligência-artificial>